

50 Startups 多元線性迴歸分析工作報告

基於 CRISP-DM 方法論的機器學習完整管線

報告日期：2026 年 6 月 12 日 | 作者：winnieshih1107 | 資料來源：
[50_Startups_hw6 GitHub Repository](#)

一、摘要

本報告依據 **CRISP-DM** (跨行業數據挖掘標準流程，Cross Industry Standard Process for Data Mining) 六大階段方法論，針對「50 家新創企業」數據集進行完整的機器學習分析，旨在建立一個能夠根據企業支出結構預測年度利潤的多元線性迴歸模型，協助投資人進行資本配置決策。

研究核心成果如下：

- 模型在測試集上達到 $R^2 = 0.9001$ ，成功超越業務設定的目標門檻 ($R^2 \geq 0.90$)
- 模型預測的平均絕對誤差約為 **\$6,979 美元**，均方根誤差為 **\$8,996 美元**
- **R&D (研發) 支出** 是影響企業利潤最關鍵的單一因素，皮爾森相關係數高達 $r = 0.9729$
- 企業所在州別 (**State**) 對利潤的影響在統計上不顯著，五種特徵選取方法均一致拒絕
- 整套分析管線已整合為可部署的 `sklearn.Pipeline` 物件，並透過 **Streamlit Cloud** 提供互動式預測介面

二、業務理解 (Phase 1: Business Understanding)

2.1 業務問題定義

本研究的核心業務問題為：「給定一家新創企業的支出結構與所在地理位置，應如何預估其年度利潤？」此問題直接關係到投資人的資本配置決策。通過建立可解釋的統計模型，投資組合管理者能夠：

- 快速評估候選企業的盈利潛力，縮短盡職調查時間
- 識別驅動利潤成長的關鍵支出類別，優化投後管理建議
- 建立系統性、可重現的投資篩選量化框架

2.2 任務設定

項目	細節
機器學習類型	有監督式學習 (Supervised Learning)
問題類型	連續值迴歸 (Regression)
目標變數	Profit (利潤，單位：USD)
業務成功指標	獨立測試集 $R^2 \geq 0.90$
模型可解釋性需求	高 (需能解讀各支出類別對利潤的邊際貢獻)

商業意義：若模型成功，投資人可據此判斷「每增加 \$1 萬的研發支出，預計可帶來多少額外利潤」，從而優化資本投入策略，指導被投企業的資源分配決策。

三、資料理解 (Phase 2: Data Understanding)

3.1 資料集概覽

數據集包含 50 家新創企業的年度財務數據，共 5 個欄位，無缺失值：

欄位名稱	類型	描述	數值範圍
R&D Spend	數值型	研究與開發支出 (USD)	\$0 – \$165,349
Administration	數值型	行政管理費用 (USD)	\$51,283 – \$182,646
Marketing Spend	數值型	行銷推廣費用 (USD)	\$0 – \$471,784
State	類別型	企業所在州 (3 個水準)	New York / California / Florida
Profit	數值型	年度利潤 (目標變數)	\$14,681 – \$192,262

敘述統計 (利潤目標變數)：平均值 \$112,013；中位數 \$107,978；標準差 \$40,306。

3.2 診斷分析六項檢查

(1) 零值檢查：R&D Spend 有 2 筆零值、Marketing Spend 有 3 筆零值，均屬合理商業現象（部分企業不從事研發或行銷）。**決策：無需插補。**

(2) 偏態分析：所有數值特徵偏度（Skewness）均在 ± 0.5 可接受範圍內，分佈趨近常態。**決策：無需對數轉換。**

特徵	偏態值	狀態
R&D Spend	+0.164	✓ 正常
Administration	-0.489	✓ 正常
Marketing Spend	-0.046	✓ 正常
Profit (目標)	+0.023	✓ 正常

(3) 異常值偵測（ $IQR \times 1.5$ 法）：三個特徵欄位均無異常值；目標變數 Profit 有 1 筆臨界值。**決策：不移除，保持完整樣本。**

(4) 特徵尺度差異：三個數值特徵的標準差差距懸殊（Marketing: \$122,290 vs Admin: \$28,018），對迴歸係數的直接比較造成干擾，且影響基於距離/正則化的方法（如 Lasso）。**決策：必須進行 StandardScaler 標準化。**

(5) 多元共線性（VIF 分析）：各特徵的方差膨脹因子（Variance Inflation Factor）均低於安全閾值 5.0。**決策：無嚴重共線性問題，三特徵可安全共存於同一模型。**

特徵	VIF 值	狀態
R&D Spend	2.47	✓ 安全
Administration	1.18	✓ 安全
Marketing Spend	2.33	✓ 安全

(6) 相關性與 OLS 顯著性分析：以 Statsmodels OLS 迴歸對全特徵集進行 p 值檢定，揭示特徵顯著性層級：

特徵	與利潤的 Pearson r	p 值	判斷
R&D Spend	0.9729	0.0000	極強顯著

特徵	與利潤的 Pearson r	p 值	判斷
Marketing Spend	0.7478	0.1227	中等，邊際顯著
Administration	0.2007	0.6077	弱相關，不顯著
State_Florida	0.1162	0.9532	可忽略
State_New York	0.0314	0.9898	可忽略

Phase 2 關鍵結論：

- State 欄位需做 One-Hot Encoding 後參與特徵選取
- 三個數值特徵需要 StandardScaler 處理尺度差異
- Administration 與 State 虛擬變數的統計顯著性存疑，需透過多方法特徵選取確認取捨

四、資料準備 (Phase 3: Data Preparation)

4.1 類別特徵編碼 (One-Hot Encoding)

State 欄位 (3 個類別) 採用 `pd.get_dummies(drop_first=True)` 進行獨熱編碼，以 California 作為參照基準組，生成兩個二元特徵，避免虛擬變數陷阱 (Dummy Variable Trap)：

原始 State 值	State_Florida	State_New York
California (參照)	0	0
Florida	1	0
New York	0	1

編碼後共有 5 個候選特徵：`R&D Spend`、`Administration`、`Marketing Spend`、`State_Florida`、`State_New York`。

4.2 特徵選取——五方法多數決

本研究採用五種獨立的特徵選取方法，以多數決 ($\geq 3/5$ 投票) 決定最終納入特徵，有效降低單一方法的選擇偏差：

特徵	方法1 相關性	方法2 SelectKBest	方法3 RFE	方法4 Lasso	方法5 隨機森林	總票數	決策
R&D Spend	✓	✓	✓	✓	✓	5/5	保留
Marketing Spend	✓	✓	✓	✓	✗	4/5	保留
Administration	✗	✓	✓	✓	✗	3/5	保留
State_Florida	✗	✗	✗	✗	✗	0/5	捨棄
State_New York	✗	✗	✗	✗	✗	0/5	捨棄

各方法細節說明：

- 方法1 相關性篩選 ($|r| \geq 0.30$)：R&D ($r=0.9729$) 和 Marketing ($r=0.7478$) 通過；Administration ($r=0.2007$) 和兩個 State 虛擬變數不通過。
- 方法2 SelectKBest F 統計 (前 $k=3$)：選出 R&D ($F=849.79$ ，遠超其他)、Marketing ($F=60.88$)、Administration ($F=2.02$)。
- 方法3 遞迴特徵消除 RFE (LinearRegression, $k=3$)：逐步剔除 State 兩個虛擬變數，保留三個數值特徵。
- 方法4 Lasso 正則化 (LassoCV, 最佳 $\alpha=388.20$)：State 虛擬變數係數在 L1 懲罰下精確縮至零；Administration 係數雖小 (-233.51) 但仍非零，因此保留。
- 方法5 隨機森林重要性 ($n=200$ 棵樹)：R&D 重要性 0.9315，遠超其他所有特徵的加總 (0.0685)，Marketing (0.0573) 低於平均值門檻，因此僅 R&D 入選。

4.3 各特徵選取方法的模型效能比較

以 80/20 固定分割評估每種方法所選特徵子集的線性迴歸性能：

特徵選取方法	所選特徵	測試集 R^2	測試集 RMSE
相關性篩選	R&D + Marketing	0.9168	\$8,206
SelectKBest	R&D + Admin + Marketing	0.9001	\$8,996
RFE	R&D + Admin + Marketing	0.9001	\$8,996
Lasso	R&D + Admin + Marketing	0.9001	\$8,996
隨機森林	R&D (單一特徵)	0.9265	\$7,714

特徵選取方法	所選特徵	測試集 R ²	測試集 RMSE
共識多數決	R&D + Admin + Marketing	0.9001	\$8,996

重要洞察：僅使用 R&D Spend 單一特徵（隨機森林方法）即能達到**最高 R² (0.9265)** 與**最低 RMSE (\$7,714)**，進一步印證 R&D 是壓倒性的利潤驅動因素。然而，多數決方案納入三特徵，提供了更穩健、更具可解釋性的模型，適合實際業務部署。

4.4 訓練/測試集分割

採用 80/20 分割（`random_state=42`，確保結果可重現性）：

- **訓練集：**40 樣本（80%），用於模型訓練與 Scaler 擬合
- **測試集：**10 樣本（20%），僅用於最終評估，不參與任何訓練決策

4.5 StandardScaler 標準化

僅對三個數值特徵套用 StandardScaler，且**嚴格在訓練集上 fit**，再 **transform** 測試集，以完全杜絕資料洩漏（Data Leakage）。二元虛擬變數保持原值不縮放（縮放 0/1 變數無意義）。

特徵	標準化前均值	標準化前標準差	標準化後均值	標準化後標準差
R&D Spend	\$77,688	\$47,898	≈ 0.000	≈ 1.013
Administration	\$121,143	\$27,454	≈ 0.000	≈ 1.013
Marketing Spend	\$235,747	\$114,864	≈ 0.000	≈ 1.013

4.6 sklearn Pipeline 架構

使用 `sklearn.pipeline.Pipeline` 將預處理器與模型整合為單一物件，確保在交叉驗證時不發生資料洩漏，且部署時僅需呼叫 `pipeline.predict()` 即可自動完成縮放與預測：

```
Pipeline([
    ("preprocessor", ColumnTransformer([
        ("scaler", StandardScaler(), ['R&D Spend', 'Administration', 'Marketing']),
        ("passthrough", "passthrough", []),
    ])),
    ("model", LinearRegression()),
])
```

五、建模 (Phase 4: Modeling)

5.1 演算法選擇

選用普通最小二乘法 (OLS) 多元線性迴歸 (`sklearn.linear_model.LinearRegression`) 。

選擇理由：

- 1. 目標變數 (Profit) 連續且分佈趨近常態，符合線性迴歸前提假設
- 2. 特徵間無嚴重共線性 (VIF < 5)，不需要 Ridge/Lasso 等正則化迴歸
- 3. 線性迴歸具備高度可解釋性，係數直接對應支出的邊際利潤貢獻，符合投資人的業務理解需求
- 4. 樣本量小 (50 筆)，複雜非線性模型 (如神經網路) 容易過擬合

5.2 模型方程式

標準化特徵上的模型方程式 (係數可直接比較各特徵的相對影響力)：

Profit = 115,651.72

+ 38,014.74 × (R&D_scaled)

+ 3,543.39 × (Marketing_scaled)

- 1,841.48 × (Admin_scaled)

5.3 標準化係數解讀

特徵	標準化係數	相對重要性	業務意義
R&D Spend	+38,014.74	最高 (10.7× > Marketing)	每增加 1 個標準差的 R&D 支出，預期利潤增加 \$38,015
Marketing Spend	+3,543.39	次要	正向但效益遠低於 R&D
Administration	-1,841.48	最弱，且為負	行政費用增加反而侵蝕利潤
截距	115,651.72	—	各特徵均值水準下的基準利潤

非標準化係數 (可直接對應實際金額)：以非標準化 OLS 估計，每增加 \$10,000 的 R&D 支出，預計帶來約 \$8,000 的額外利潤 (利潤轉化率約 80%)。

六、評估 (Phase 5: Evaluation)

6.1 訓練集 / 測試集效能指標

指標	訓練集	測試集	業務目標	達成狀態
R ² (決定係數)	0.9536	0.9001	≥ 0.90	✅ 達標
MAE (平均絕對誤差)	\$6,597	\$6,979	—	—
RMSE (均方根誤差)	\$8,938	\$8,996	—	—
MAPE (平均絕對百分比誤差)	10.92%	10.32%	—	—

測試集 R² = **0.9001** 恰好達到業務目標門檻 (≥ 0.90)，表示模型能夠解釋 **90%** 的利潤變異。訓練與測試的 R² 差距約 0.053，屬於正常的訓練/測試差異，無嚴重過擬合跡象。

6.2 殘差分析

- 殘差 (Residuals = 實際值 – 預測值) 呈現以下特性：
- 圍繞零值對稱分佈，無明顯的系統性偏差 (非恆偏高或偏低)
 - 在預測值的全域範圍內，殘差幅度相對穩定 (近似同質變異數)
 - 殘差直方圖接近鐘形分佈，符合線性迴歸的常態殘差假設
 - 最大預測誤差出現在低利潤範圍 (\$14K-\$50K)，可能因為小樣本在低端的代表性不足

6.3 五折交叉驗證 (5-Fold Cross-Validation)

折次	R ²
Fold 1	0.8931
Fold 2	-0.8112
Fold 3	-0.4193
Fold 4	-0.7012
Fold 5	0.4304
平均 ± 標準差	-0.12 ± 0.67

⚠️ **特別說明——小樣本 CV 不穩定性**：CV 結果呈現極高的波動（部分 Fold 出現負 R^2 ），這是**小樣本問題**而非模型缺陷。50 筆樣本分成 5 折，每折測試集僅 **8 筆**。若某折恰巧集中抽到低利潤或高利潤的同質企業，預測值分佈極窄， R^2 自然失真甚至為負。

以**固定 80/20 分割**（`random_state=42`，10 筆具代表性的測試樣本）作為主要評估基準更為**可靠**。若需增強 CV 穩健性，建議待樣本累積至 100+ 筆再重新評估。

6.4 樣本預測展示

企業情境	R&D 支出	行政費用	行銷費用	預測利潤
高 R&D 投入型	\$150,000	\$120,000	\$300,000	\$175,860
中等均衡型	\$50,000	\$100,000	\$100,000	\$90,592
零研發型	\$0	\$80,000	\$50,000	\$50,200

七、部署 (Phase 6: Deployment)

7.1 技術部署架構

整個 `sklearn.Pipeline`（含 `ColumnTransformer` 縮放器與 `LinearRegression` 模型）可透過 `joblib.dump()` 序列化為單一 `.pkl` 物件：

- **部署優勢**：無需另外儲存縮放參數，大幅降低線上推論時縮放器與模型不同步的錯誤風險
- **推論接口**：僅需呼叫 `pipeline.predict(new_data)` 即可自動完成標準化與預測，輸入原始數值即可

使用示例：

```
import pandas as pd

new_startup = pd.DataFrame({
    "R&D Spend":      [80000],
    "Administration": [110000],
    "Marketing Spend": [200000],
})
predicted_profit = pipeline.predict(new_startup)
print(f"預測利潤：${predicted_profit[0]:.2f}")
# 輸出：預測利潤：$117,845.52
```

7.2 Streamlit 互動式 Web 應用程式

基於 Streamlit 框架開發的「**Startup Profit Predictor**」儀表板，已部署至 **Streamlit Cloud**，提供以下功能模組：

功能模組	描述
KPI 指標卡片	即時顯示 R^2 、RMSE、MAE、最佳方法等核心指標
10 方法效能比較圖	橫向長條圖比較 10 種特徵選取方法的測試 R^2 與 RMSE
特徵共識分析	視覺化各方法的投票結果與特徵入選比率
即時預測模擬器	拖拉滑桿輸入 R&D / Admin / Marketing 支出，即時輸出預測利潤
完整方法比較表	可排序的互動表格，列出所有方法的詳細指標

八、結論與投資建議

8.1 核心發現摘要

發現一：R&D 支出是壓倒性的利潤驅動力

- 皮爾森相關係數 $r = 0.9729$ (極強線性關係)
- 隨機森林特徵重要性 **0.9315** (其他所有特徵合計僅 0.0685)
- 標準化迴歸係數 **+38,015** (Marketing 的 10.7 倍)
- 每增加 \$10,000 的研發支出，預期帶來約 **\$8,000** 的額外利潤

發現二：地理位置 (州別) 影響可忽略

- 五種特徵選取方法一致拒絕 State 虛擬變數 (**0/5 投票**)
- OLS p 值 > 0.95 ，在任何顯著性水準下均不顯著
- 企業選擇在 New York、California 或 Florida 設立，對利潤**無顯著差異**

發現三：行政費用存在輕微負向效應

- 迴歸係數為 **-1,841**，方向為負
- 3/5 方法仍選擇保留此特徵，表示雖弱但仍有統計資訊量
- 過高的行政管理費用可能侵蝕利潤，建議合理控制管理成本比例

發現四：行銷支出效益次於 R&D 但仍正向

- 標準化係數 **+3,543**，約為 R&D 效應的 **1/10.7**

- 在確保 R&D 充分投入後，行銷預算擴張仍有利潤增益
- 4/5 方法選擇保留此特徵，具備一定的模型貢獻度

8.2 量化投資建議

基於模型係數，以下為三種典型企業的最優化資源配置建議：

企業類型	建議策略	預期利潤影響
早期新創 (資金有限)	將至少 60% 可支配預算優先投入 R&D	利潤提升效益最大化
成長期企業	R&D 優先 + 適度行銷，嚴控行政成本比率 < 25%	維持高利潤率同時擴展市場
成熟企業	平衡 R&D 與 Marketing，精簡管理架構	防止行政費用侵蝕邊際利潤

8.3 模型限制與後續研究方向

1. **小樣本限制**：50 筆數據的統計功效有限，建議累積至 **100–200 筆**後重新建模以提升模型穩健性
2. **時間序列缺失**：當前數據缺乏時間維度，無法捕捉年份趨勢或季節性效應，建議未來納入多年度數據
3. **特徵工程潛力**：可考慮新增「R&D 占總支出比例」等衍生特徵，可能進一步提升模型解釋力
4. **非線性建模**：對於更大規模數據集，Gradient Boosting 或隨機森林迴歸可能提供更精準的預測
5. **外部因素**：當前模型未包含宏觀經濟指標（如市場利率、行業景氣指數），限制了跨行業的泛化能力

8.4 技術實作總結

項目	實作細節
資料集	50 家新創企業，5 個欄位，無缺失值
演算法	多元線性迴歸 (OLS，sklearn)

項目	實作細節
特徵選取	5 方法多數決 (相關性 / SelectKBest / RFE / LassoCV / RandomForest)
最終特徵	R&D Spend、Marketing Spend、Administration (3 個特徵)
資料預處理	One-Hot Encoding + StandardScaler (Pipeline 整合，無洩漏)
測試集 R ²	0.9001  達成業務目標
測試集 RMSE	\$8,996
測試集 MAE	\$6,979
開發工具	Python 3.x / pandas / numpy / scikit-learn / statsmodels / Streamlit / Plotly
部署方式	Streamlit Cloud 互動式儀表板

附錄：關鍵圖表說明


圖表編號	檔案名稱	內容
圖 2a	<code>phase2a_distributions.png</code>	4 個特徵的直方圖分佈、State 長條圖、相關性熱力圖
圖 2b	<code>phase2b_diagnosis.png</code>	3 個特徵 vs Profit 散點圖 (含趨勢線) 及箱型圖 (離群值偵測)
圖 3a	<code>phase3a_feature_selection.png</code>	5 方法選取矩陣熱力圖 + 投票數長條圖
圖 3b	<code>phase3b_scaling.png</code>	StandardScaler 前後箱型圖比較
圖 3c	<code>phase3c_performance.png</code>	6 種方法的 R ² (訓練/測試) 和 RMSE 比較
圖 5	<code>phase5_evaluation.png</code>	實際值 vs 預測值散點圖、殘差圖、係數圖、CV 折疊圖、效能彙總表

本報告依據 [winnieshih1107/50_Startups_hw6](#) [GitHub](#) 儲存庫中的完整程式碼與實驗結果撰寫。

附錄：完整分析圖表


以下圖表依 CRISP-DM 各分析階段排列，涵蓋資料理解 (Phase 2)、資料準備 (Phase 3) 及模型評估 (Phase 5) 的完整視覺化輸出。

圖 A-1 Phase 2a — 特徵分佈與相關係數矩陣




四個數值欄位的直方圖 (含偏態值)、州別企業數長條圖，以及 Profit 與三個特徵間的 Pearson 相關係數熱力圖。R&D Spend 與 Profit 的相關係數高達 0.973，為最強預測因子。

圖 A-2 Phase 2b — 特徵診斷 (散點圖 / 箱型圖)




左排：三個特徵對 Profit 的散點圖，附迴歸趨勢線與相關係數 r 值。右排：對應的箱型圖，紅點標示以 $IQR \times 1.5$ 判定的離群值（三特徵均無異常值）。

圖 A-3 Phase 3a — 五方法特徵選取共識矩陣




左：5×5 選取矩陣（綠=保留，紅=捨棄）。右：各特徵總票數長條圖，虛線為 3/5 共識門檻。R&D Spend 獲得全票（5/5），State 虛擬變數得 0 票一致捨棄。

圖 A-4 Phase 3d — 隨機森林特徵重要性




n_estimators=200 的隨機森林計算各特徵的 Gini 重要性。R&D Spend 的重要性高達 0.9315，遠超其他所有特徵的總和 (0.0685)，紅線為平均值門檻。

圖 A-5 Phase 3b — StandardScaler 標準化效果




左：原始尺度箱型圖 (Marketing Spend std=\$122K vs Administration std=\$28K，差距懸殊)。右：StandardScaler 後各特徵均值趨近 0、標準差趨近 1，係數可直接比較。

圖 A-6 Phase 3c — 六種特徵選取方法效能比較



左：Train/Test R² 並排長條圖，紅虛線為目標 R²=0.90。右：測試集 RMSE 比較，隨機森林方法（僅 R&D 特徵）達到最低 RMSE=\$7,714。

圖 A-7 Phase 5 — 完整模型評估結果



包含六個子圖：實際值 vs 預測值散點圖（R²=0.9001）、殘差 vs 預測值圖、殘差分佈直方圖、標準化迴歸係數長條圖、五折交叉驗證 R² 及效能指標彙總表。